

Dia 2. Introducción al R básico

Acceso a datos en tablas.

Funciones básicas. Estructuras de control.

Visualización de datos geográficos en R.

Universidad de Guadalajara, CUCSH-CUCBA Viacheslav Shalisko 16–24.07.2019

Datos fuente

La tabla de datos Datos_del_censo.csv – contiene fragmento de estudio del arbolado con DAP ≥ 5 cm en los Centros Universitarios de la UdeG (datos del 2016)

Así se ve el código en el editor de RStudio

El resultado de ejecución con el compilador Knit

```
12 - ### A. Cargar la tabla de datos
13 - #### Estructura de datos (tabla `Datos_del_censo.csv`):
   1. *Centro* - código del CU
  2. *Especie* - nombre científico
  3. *Codigo* - identificador único del arbol
  4. *AB* - área basal del árbol (dm^2^)
18 5. *DTr* - diametro del tronco equivalente (cm)
19 6. *Alt* - estatura del árbol (m)
20 7. *DCop* - diametro promedio de la copa (m)
   8. *ExcCop* - excentricidad de la copa
22
23 + ```{r}
   arbolado <- read.csv("Materiales/Datos_del_censo.csv")</pre>
    dim(arbolado)
26 -
28
29
       fragmento del código R ("chunk")
30
31
32
33
```

A. Cargar la tabla de datos

Estructura de datos (tabla Datos del censo.csv):

- 1. Centro código del CU
- 2. Especie nombre científico
- 3. Codigo identificador único del arbol
- 4. AB área basal del árbol (dm2)
- 5. DTr diametro del tronco equivalente (cm)
- 6. Alt estatura del árbol (m)
- 7. DCop diametro promedio de la copa (m)
- 8. ExcCop excentricidad de la copa

```
arbolado <- read.csv("Materiales/Datos_del_censo.csv")
dim(arbolado)</pre>
```

[1] 4785

8

Datos fuente

```
head(arbolado) 
Verificación de calidad de lectura de tabla
```

```
Especie Codigo AB DTr Alt DCop ExcCop
     Centro
##
## 1 CUCOSTA Pithecellobium dulce C10-3-1 13.21 41.0 9.8 15.4
                                                                0.30
                  Acacia macracantha C10-3-10 1.91 15.6 4.4 4.7
## 2 CUCOSTA
                                                                0.63
## 3 CUCOSTA Pithecellobium lanceolatum C10-3-100 0.95 11.0 6.4 9.5
                                                                0.91
## 4 CUCOSTA
                  Salix bonplandiana C10-3-1000 0.83 10.3 7.7 4.9 0.20
                      Tabebuia rosea C10-3-1001 0.28 6.0 2.4 2.0 0.63
## 5 CUCOSTA
## 6 CUCOSTA Pithecellobium lanceolatum C10-3-1002 0.51 8.1 4.1 4.3
                                                                0.71
```

tail(arbolado)

```
## Centro Especie Codigo AB DTr Alt DCop ExcCop ## 4780 CUCSUR Araucaria heterophylla C9-3-94 6.97 29.8 16.2 5.5 0.50 ## 4781 CUCSUR Ficus benjamina C9-3-95 17.60 47.3 11.5 10.2 0.38 ## 4782 CUCSUR Simarouba glauca C9-3-96 2.63 18.3 11.5 9.4 0.58 ## 4783 CUCSUR Jacaranda mimosifolia C9-3-97 76.95 99.0 20.6 13.0 0.57 ## 4784 CUCSUR Jatropha cordata C9-3-98 2.11 16.4 2.7 3.6 0.23 ## 4785 CUCSUR Jacaranda mimosifolia C9-3-99 7.55 31.0 18.2 5.2 0.77
```

Datos fuente

Estructura del objeto arbolado

```
str(arbolado)
```

levels(arbolado\$Centro)

```
## [1] "CUALTOS" "CUCIENEGA" "CUCOSTA" "CUCSUR"
```

Subconsultas

Más ejemplos de extracción desde un dataframe:

```
arbolado[arbolado$DTr > 10,]

    extraer registros para arbolado con DAP mayor que 10 cm

arbolado[arbolado$Centro == 'CUCSUR',]

    extraer registros para arbolado de CUCSUR

arbolado[arbolado[,1] == 'CUCSUR',]
        - lo mismo
arbolado[arbolado$Centro == 'CUCSUR' & arbolado$DTr > 10,]

    extraer registros para arbolado de CUCSUR con DAP > 10 cm

arbolado[arbolado$Centro == 'CUCSUR' & arbolado$DTr > 10,
                                                            c("AB","Alt")]

    extraer área basal y estatura para arbolado de CUCSUR con DAP > 10 cm
```

summary

```
summary(arbolado[,c(1,2,4:8)]) 			 Seleccionamos solo columnas de interés
```

```
Especie
##
        Centro
                                                 AB
                                            Min. : 0.200
## CUALTOS :1828 Quercus resinosa : 530
## CUCIENEGA: 445 Pithecellobium lanceolatum: 501 1st Qu.: 0.950
## CUCOSTA :2143 Guazuma ulmifolia : 329 Median : 2.780
## CUCSUR : 369 Fraxinus uhdei : 278 Mean : 5.817
##
                 Eysenhardtia polystachya : 245
                                            3rd Qu.: 6.610
                 Acacia macracantha : 176
##
                                            Max. :456.340
##
                 (Other)
                                 :2726
##
       DTr
                   Alt
                                  DCop ExcCop
   Min. : 5.00 Min. : 1.500 Min. : 0.200 Min. : 0.0000
   1st Qu.: 11.00    1st Qu.: 4.200    1st Qu.: 3.800    1st Qu.:0.3700
   Median: 18.80 Median: 6.200 Median: 5.500 Median: 0.5100
##
   Mean : 22.22 Mean : 7.121 Mean : 6.165
                                            Mean :0.5026
##
## 3rd Qu.: 29.00 3rd Qu.: 9.100 3rd Qu.: 7.900 3rd Qu.:0.6500
   Max. :241.00 Max. :26.600
                              Max. :64.500 Max. :0.9900
##
                NA's :46
##
                                Variable sin datos
```

mean, median, sd, var, quantile

Las funciones básicas de la estadistica descriptiva incluyen:

- Promedio y mediana mean(), median()
- 2. Mínimo, máximo y rango min(), max(), range()
- 3. Desviación estandar y varianza sd(), var()
- 4. Quantiles y rango intercuartilico quantile(), IQR()

```
summary(arbolado$AB)
```

```
## Min. 1st Qu. Median Mean 3rd Qu. Max.
## 0.200 0.950 2.780 5.817 6.610 456.300
```

range(arbolado\$AB)

```
## [1] 0.20 456.34
```

quantile(arbolado\$AB)

```
## 0% 25% 50% 75% 100%
## 0.20 0.95 2.78 6.61 456.34
```

```
IQR(arbolado$AB)
```

```
## [1] 5.66
```

```
var(arbolado$AB)
```

```
## [1] 173.8403
```

sqrt(var(arbolado\$AB))

[1] 13.18485

sd(arbolado\$AB)

[1] 13.18485

quantile, boxplot.stats

Función *quantile* se puede emplear para subdividir la distribución de valores bajo reglas arbitrarias, determinar cuartiles, percentiles o cualquier otra secuencia de probabilidades.

```
probabilidades <- c(0.01,0.05,0.1,0.5,0.9,0.95,0.99)
quantile(arbolado$AB, probs = probabilidades)

## 1% 5% 10% 50% 90% 95% 99%
## 0.200 0.270 0.410 2.780 12.956 19.630 44.436</pre>
```

Función *boxplot.stats* puede ser útil para discriminar los valores atípicos. Este procedimiento depende del umbral *coef* definido en los parámetros, valor por defecto coef=1.5

```
boxplot.stats(arbolado$AB)$stats
## [1] 0.20 0.95 2.78 6.61 15.00
```

```
boxplot.stats(arbolado$AB, coef = 3)$stats
## [1] 0.20 0.95 2.78 6.61 23.52
```

aggregate

Estadísticas por grupos se puede calcular empleando función aggregate.

Nota que los grupos deben estar definidos como variable de tipo factor.

```
aggregate(arbolado$AB ~ arbolado$Centro, FUN = sum)
```

```
## arbolado$Centro arbolado$AB

## 1 CUALTOS 8521.96

## 2 CUCIENEGA 3478.53

## 3 CUCOSTA 12647.99

## 4 CUCSUR 3184.82
```

```
aggregate(arbolado$AB ~ arbolado$Centro, FUN = length)
```

aggregate

```
{\tt aggregate}({\tt arbolado\$AB} \ \sim \ {\tt arbolado\$Centro}, \ {\tt FUN} \ = \ {\tt mean})
```

```
## 1 CUALTOS 4.661904
## 2 CUCIENEGA 7.816921
## 3 CUCOSTA 5.902002
## 4 CUCSUR 8.630949
```

```
aggregate(arbolado$AB ~ arbolado$Centro, FUN = range)
```

```
## 1 CUALTOS 0.20 114.36
## 2 CUCIENEGA 0.23 77.44
## 3 CUCOSTA 0.20 456.34
## 4 CUCSUR 0.21 419.84
```

apply, lapply, sapply, tapply, mapply

Estadistica por columnas y/o grupos

El grupo de funciones apply permite realizar operaciones de forma cíclica sin necesidad de definir un ciclo de manera formal:

- 1. lapply() aplicar una función a cada elemento de una lista, resultado es una lista de mismo largo que lista de entrada
- 2. sapply() lo mismo que lapply(), pero con resultado simplificado (vector, matriz o array)
- 3. apply() aplicar una función sobre dimensiones de un matriz de datos

aggregate(arbolado\$AB ~ arbolado\$Centro, FUN = mean)

- 4. tapply() aplicar una función sobre grupos definidos en un vector, similar a aggregate()
- mapply() versión multivariante de tapply()

Compara

```
tapply(arbolado$AB, arbolado$Centro, FUN = mean)

## CUALTOS CUCIENEGA CUCOSTA CUCSUR
## 4.661904 7.816921 5.902002 8.630949
```

```
## arbolado$Centro arbolado$AB
## 1 CUALTOS 4.661904
## 2 CUCIENEGA 7.816921
## 3 CUCOSTA 5.902002
## 4 CUCSUR 8.630949
```

lapply, sapply

```
Compara lapply() y sapply()
 lapply(arbolado[,4:8],sd,na.rm = TRUE)____
 ## $AB
 ## [1] 13.18485
 ##
 ## $DTr
 ## [1] 15.71243
 ##
 ## $Alt
 ## [1] 3.847538
 ##
 ## $DCop
 ## [1] 3.352365
 ## $ExcCop
 ## [1] 0.2009095
```

Nota que se agrega el parámetro para omitir valores sin datos, el mismo parámetro se puede aplicar a funciones individuales.

```
sd(arbolado$Alt, na.rm = TRUE)
```

[1] 3.847538

```
sapply(arbolado[,4:8],sd,na.rm = TRUE)

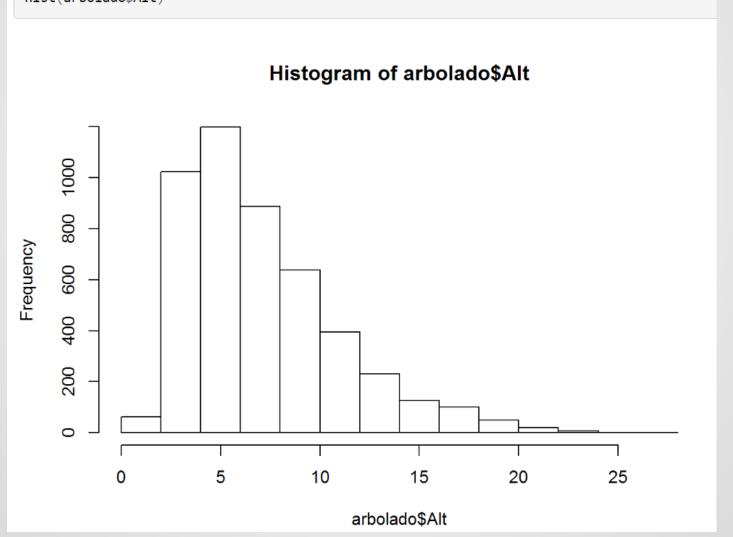
## AB DTr Alt DCop ExcCop
## 13.1848514 15.7124261 3.8475377 3.3523652 0.2009095
```

sapply

```
sapply(arbolado[,4:8],range,na.rm = TRUE)
## AB DTr Alt DCop ExcCop
## [1,] 0.20 5 1.5 0.2 0.00
## [2,] 456.34 241 26.6 64.5 0.99
sapply(arbolado[,4:8],function(x) length(x[!is.na(x)]))
                                            función anónima
## AB DTr Alt DCop ExcCop
## 4785 4785 4739 4785 4785
```

A veces se puede definir una *función anónima* en la misma estructura de *apply*. Es el método muy común de uso de las estructuras apply.

hist(arbolado\$Alt)



```
hist(arbolado$Alt,

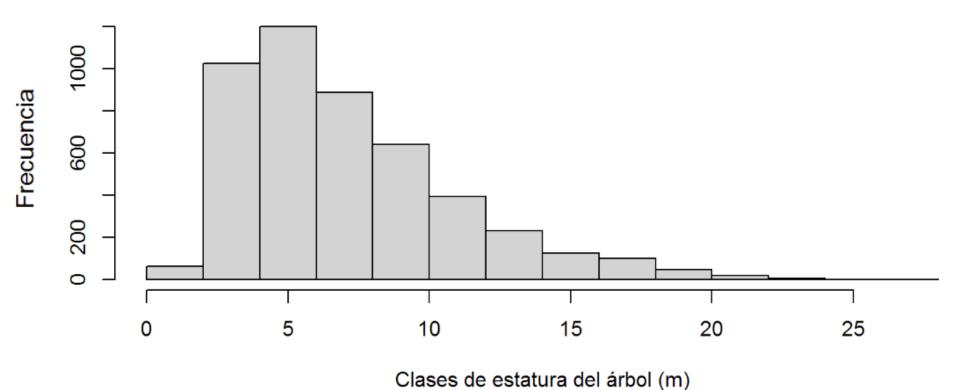
col = "lightgray",

xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",

main = "Histográma de estaturas")
```

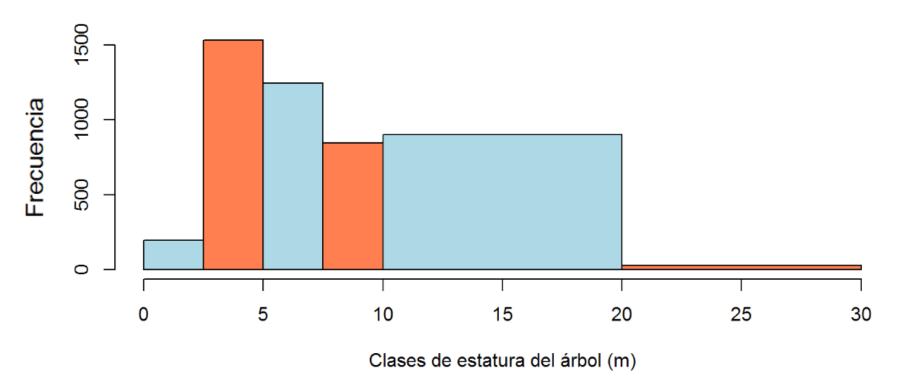
Parámetros del "chunk".

Histográma de estaturas



```
hist(arbolado$Alt,
    col = c("lightblue","coral"),
    xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
    main = "Histográma de estaturas",
    breaks = c(0,2.5,5,7.5,10,20,30), prob = FALSE)
```

Histográma de estaturas



```
H0 <- hist(arbolado$Alt,
    col = c("lightblue","coral"),
    xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
    main = "Histográma de estaturas",
    breaks = c(0,2.5,5,7.5,10,20,30), prob = FALSE)</pre>
```

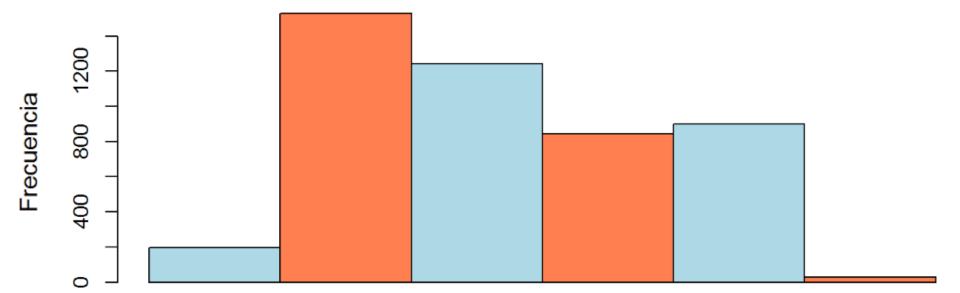
str(H0)

```
## List of 6
## $ breaks : num [1:7] 0 2.5 5 7.5 10 20 30
## $ counts : int [1:6] 196 1529 1242 844 900 28
## $ density : num [1:6] 0.0165 0.1291 0.1048 0.0712 0.019 ...
## $ mids : num [1:6] 1.25 3.75 6.25 8.75 15 25
## $ xname : chr "arbolado$Alt"
## $ equidist: logi FALSE
## - attr(*, "class")= chr "histogram"
```

barplot

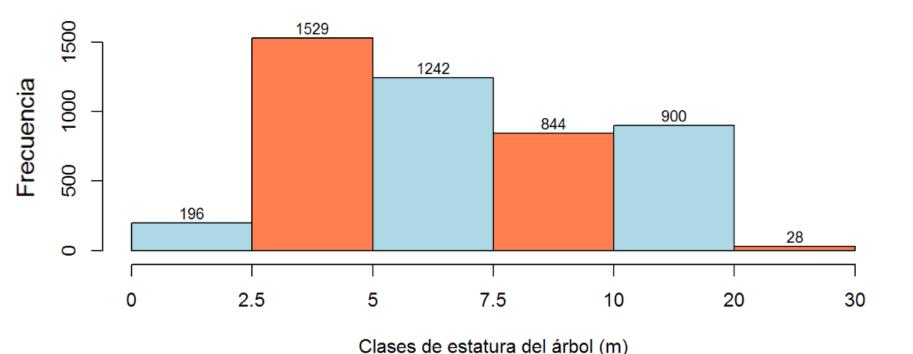
```
barplot(H0$counts, space = 0,
    col = c("lightblue","coral"),
    xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
    main = "Histográma de estaturas")
```

Histográma de estaturas



barplot

Histográma de estaturas



La función *plot* ofrece gran flexibilidad en elaboración de las graficas bidimensionales.

Parámetros para colocar 2 gráficas en un cuadro

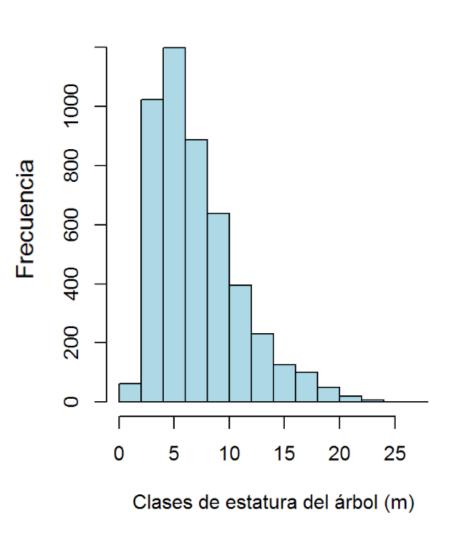
```
par(mfcol = c(1, 2))

hist(arbolado$Alt,
    col = c("lightblue"),
    xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
    main = "Histográma de estaturas", prob = FALSE)

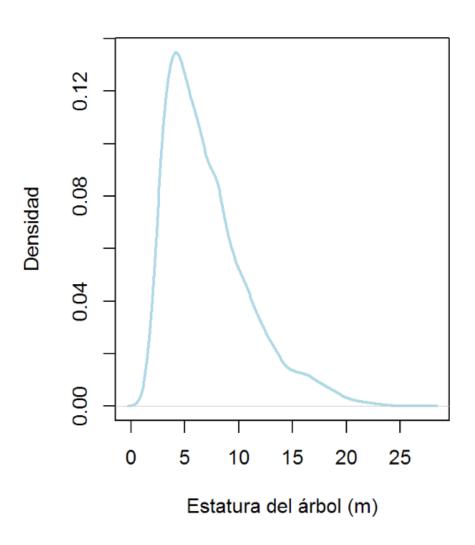
plot(density(arbolado$Alt, na.rm = TRUE),
    col = c("lightblue"), lty=1, lwd=2,
    xlab = "Estatura del árbol (m)", ylab = "Densidad",
    main = "Distribución de estaturas")
```

plot vs. hist

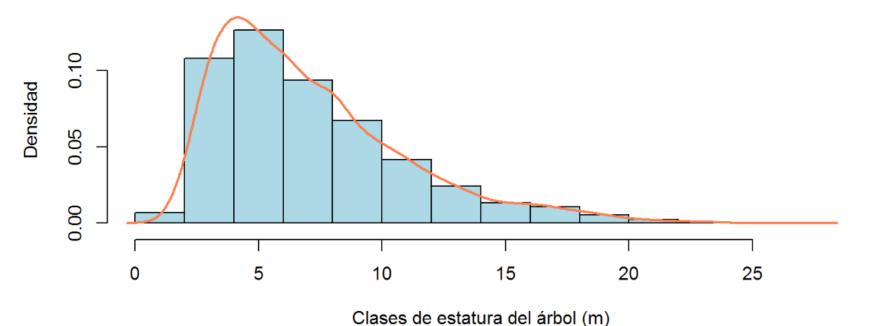
Histográma de estaturas



Distribución de estaturas



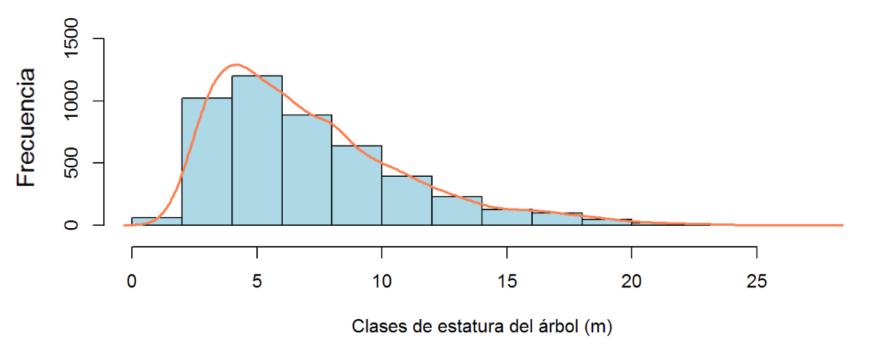
Histográma de estaturas con gráfica de densidad de distribución



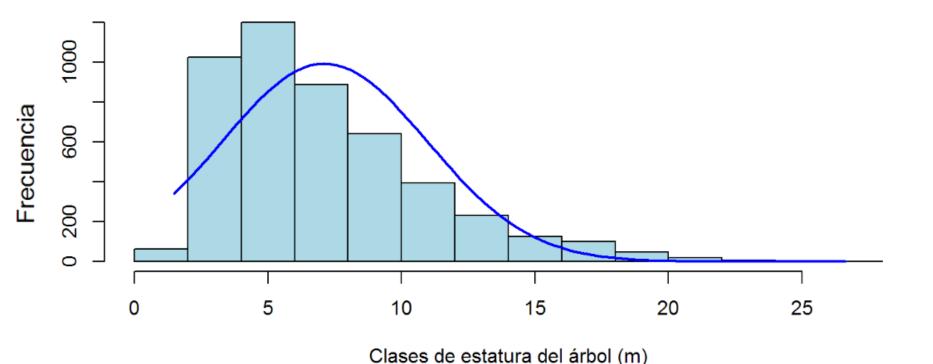
```
H2 <- hist(arbolado$Alt, ylim = c(-100,1700),
        col = c("lightblue"),
        xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
        main = "Histográma de estaturas con gráfica de densidad de distribución", prob = FALSE)

densidad <- density(arbolado$Alt, na.rm = TRUE)
densidad$y <- densidad$y*diff(H2$mids[1:2])*length(arbolado$Alt)
lines(densidad, col = c("coral"), lty=1, lwd=2)</pre>
```

Histográma de estaturas con gráfica de densidad de distribución

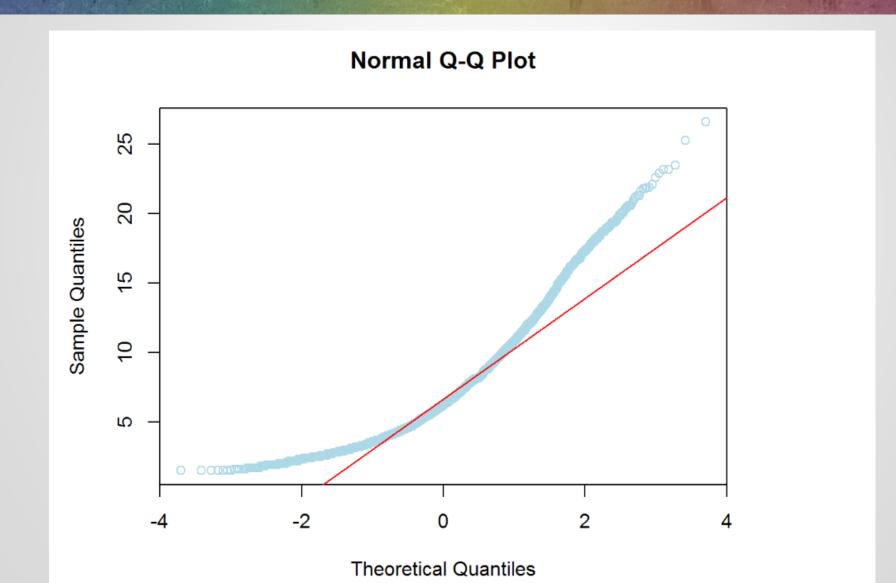


Histográma de estaturas con grafica de distribución normal

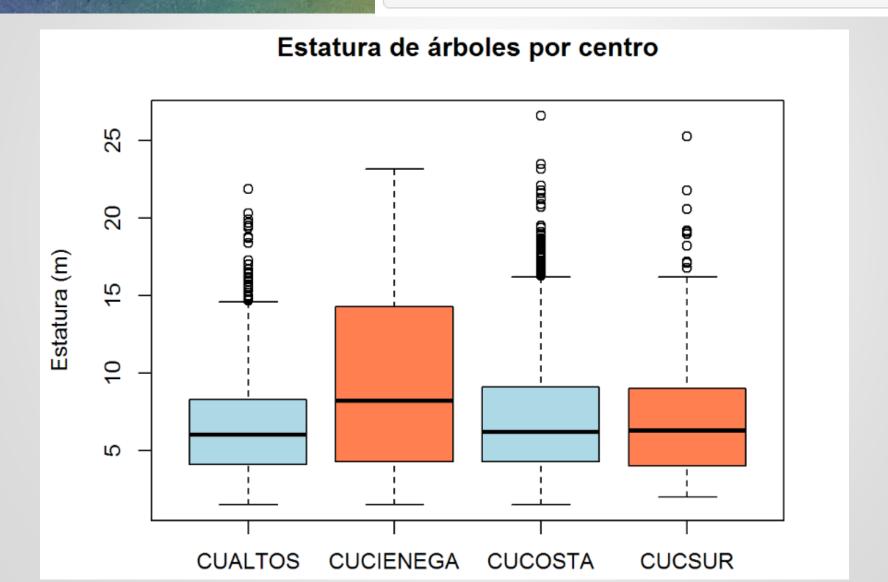


qqnorm

```
qqnorm(arbolado$Alt, col = "lightblue")
qqline(arbolado$Alt, col = "red")
```

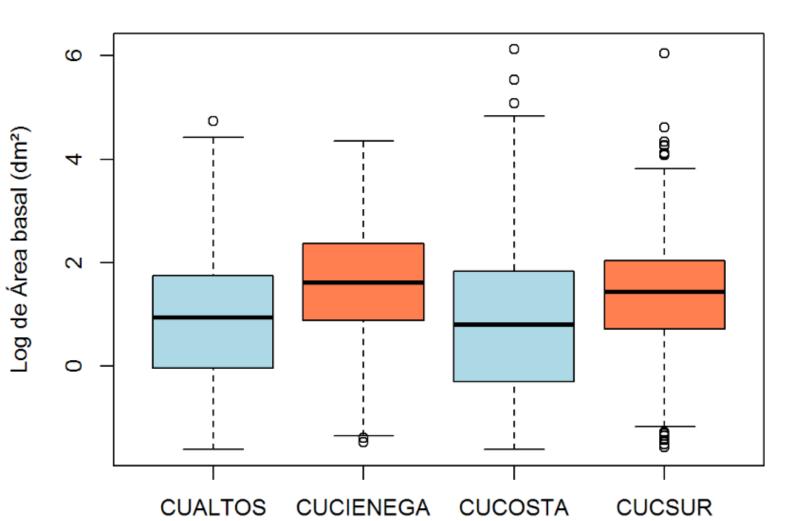


boxplot

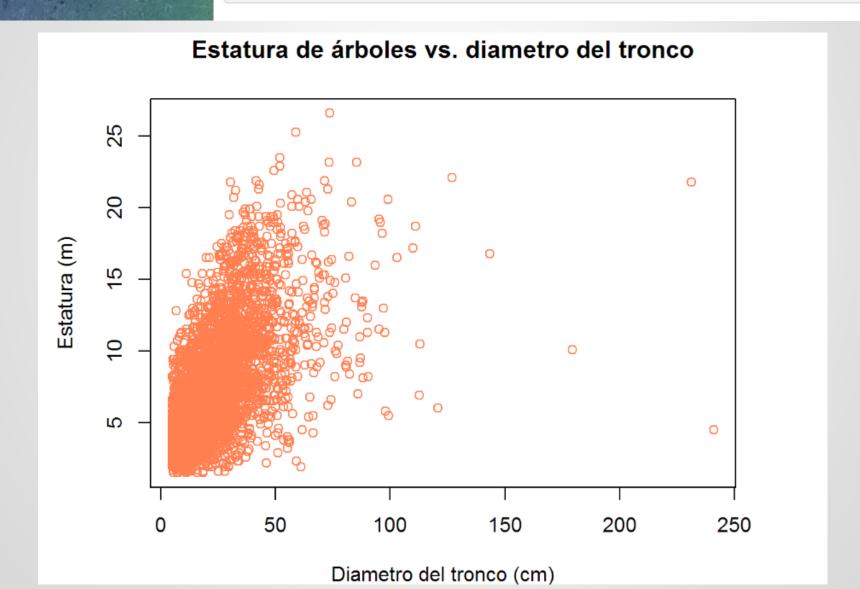


boxplot

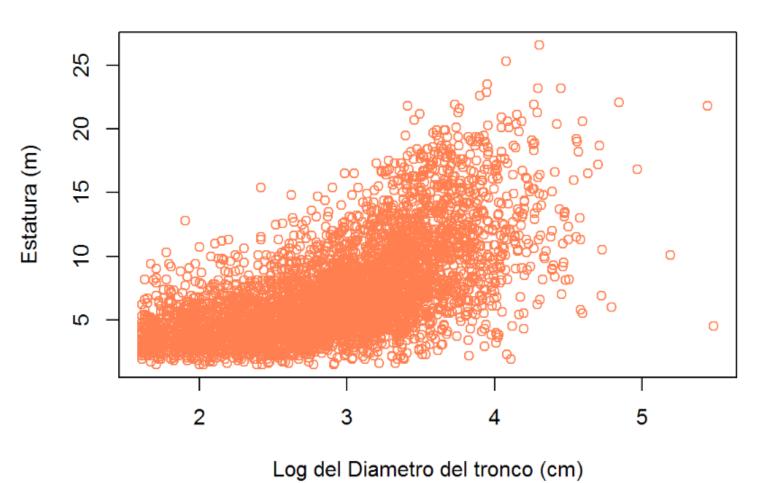
Área basal de árboles por centro







Estatura de árboles vs. diametro del tronco

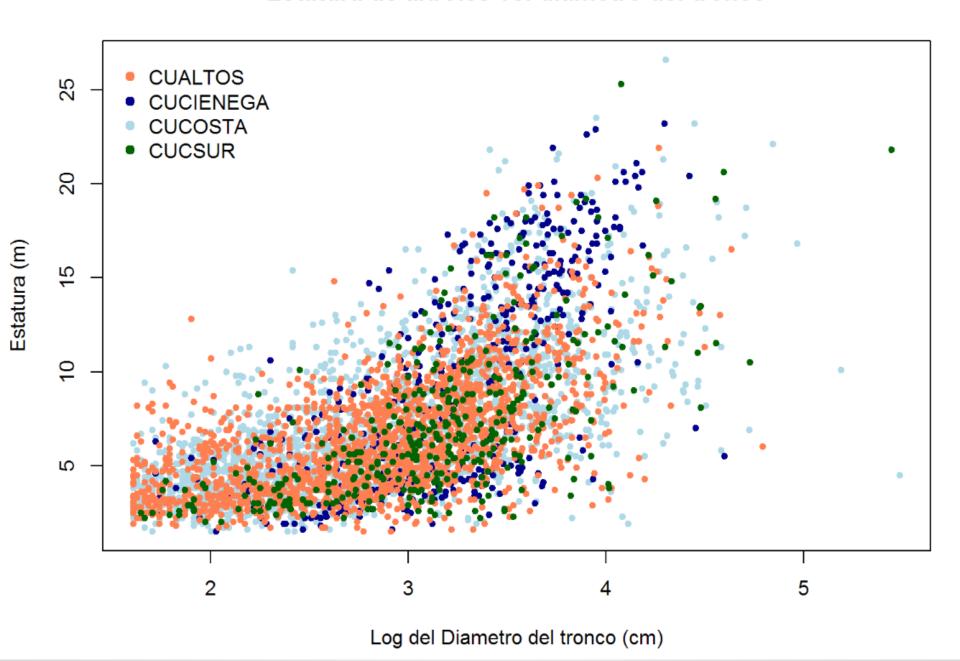


plot

Vector de cuatro colores se asocia con los cuatro niveles del factor presentes en la variable categórica

Nombres de niveles de variable categórica se usan como parámetros de leyenda, y la secuencia de cuatro colores como parámetro col

Estatura de árboles vs. diametro del tronco



funciones

Sintáxis general de definición de las funciones

```
nombre_de_función <- function(variables_de_entrada) {
cuerpo de función donde se usan las variables de entrada y se genera valor de salida
}
```

Existen la dos formas de definición de las funciones:

- a) en una sola linea
- b) con el bloque encerrado en los símbolos {}

Las funciones pueden ser anónimas o tener el nombre

```
trim <- function(x) gsub("^\\s+|\\s+$", "", x)
simpleCap <- function(x) {
   paste(toupper(substr(x, 1, 1)), substr(x, 2, nchar(x)), sep="")
}</pre>
```

funciones

Aplicacion de las funciones para depurar nombres de las especies

```
lista_especies <- unique(as.character(arbolado$Especie))
length(lista_especies)</pre>
```

```
## [1] 150
```

```
arbolado$Especie <- sapply(as.character(arbolado$Especie), simpleCap)
arbolado$Especie <- sapply(arbolado$Especie, trim)
lista_depurada_especies <- unique(arbolado$Especie)
arbolado$Especie <- as.factor(arbolado$Especie)

length(lista_depurada_especies)</pre>
```

```
## [1] 144
```

Estructuras de control

Elementos de control de flujo de ejecución

- 1. if, else, else if estructuras condicionales
- 2. for ciclos (loops, bucles) con un número predeterminado de iteraciones
- 3. while ciclos con un número indefinido de iteraciones
- 4. repeat ciclos con un número infinito de iteraciones (se usan rara vez, principalmente en elementos de interface de usuario)
- 5. next, return elementos que permiten interrimpir o saltar iteraciones en los ciclos

Sintáxis general de las estructuras condicionales

```
if(condición lógica) {
  código para caso que la condición se cumple
} else {
  código para caso que la condición no se cumple
}
```

Sintáxis general de los ciclos con numero predeterminado de elementos

```
for(iterador in rango_de_posibles_valores_del_iterador) {
  código del cuerpo de ciclo, donde se puede utilizar iterador como una variable
}
```

Estructuras de control (ejemplo)

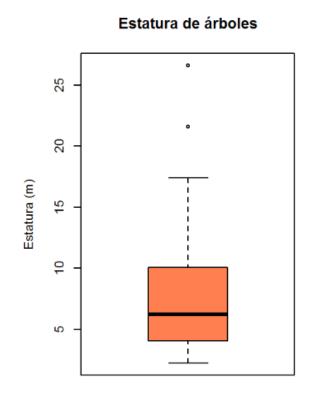
Ejemplo:

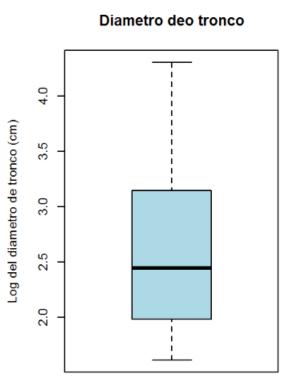
```
for(i in 1:length(lista depurada especies)){
  # seleccionar registros que corresponden a una especie determinada
  tabla_especie <- arbolado[arbolado$Especie == lista_depurada_especies[i],]
  # verificar que número de árboles de la especie es mayór que 50
  if(dim(tabla especie)[1] > 50) {
    # imprimir nombre de especie y número de árboles
    cat(paste("<h4><i>",lista depurada especies[i],"</i></h4>"))
    cat(paste('<code>',"n =",dim(tabla especie)[1],"</code>"))
    # especificar lienzo para tres graficas
    par(mfcol = c(1, 3))
    # dobujar tres graficas
    boxplot(tabla especie$Alt,
        col = "coral", main = "Estatura de árboles", ylab = "Estatura (m)")
    boxplot(log(tabla_especie$DTr),
        col = "lightblue", main = "Diametro deo tronco", ylab = "Log del diametro de tronco (cm)")
    plot(tabla_especie$Alt ~ log(tabla_especie$DTr),
        col = "coral", main = "Estatura vs. diametro del tronco",
       ylab = "Estatura (m)", xlab = "Log del diametro del tronco (cm)")
```

Estructuras de control (ejemplo)

Tabebuia rosea

n = 159





Estatura vs. diametro del tronco 20 Estatura (m) 10 3.5

Log del diametro del tronco (cm)

Estructuras de control

Seguir con ponencia de R. Peng de John Hopkins University (disponible en Coursera, parte del curso "R programming")



https://www.youtube.com/watch?v=s h9ruNwl 0

Introduction to the R Language

Control Structures

Roger Peng, Associate Professor Johns Hopkins Bloomberg School of Public Health

PROFACAD: Producto 4 para el portafolio

Producto para el portafolio: Producto 4. Ejercicio 3

Fecha de entrega del producto: 26 de julio 2019

Ejercicio 3: En equipos de 2 alumnos definir y aplicar una función que permita realizar la generación de los histogramas y diagramas de caja para los parámetros biométricos (estatura y DAP) de arbolado por especie en los datos del censo de arbolado en los Centros Universitarios de la Universidad de Guadalajara, solo para las especies con $N \ge 50$.

Producto para el portafolio: Reporte en el formato del documento R Markdown PDF con los fragmentos de código insertados que contiene los resultados de ejecución de la función definida en conformidad con las condiciones del ejercicio 3.

Estructuras de datos en R

Bibliografía complementaria

Mendoza Vega, J. B. (2018). *R para principiantes*. Libro electrónico recuperado de https://bookdown.org/jboscomendoza/r-principiantes4/

Peng, R. D. (2016). *R Programming for Data Science*. Leanpub. https://leanpub.com/rprogramming

Wickham. H. y Grolemund, G. (2017). *R for Data Science*. O'Reilly. http://r4ds.had.co.nz/