

### Taller Introducción a R básico.

Días 3-4: estadística básica, gráficas, estructuras de control

#### **Entorno**

RStudio 0.99.902

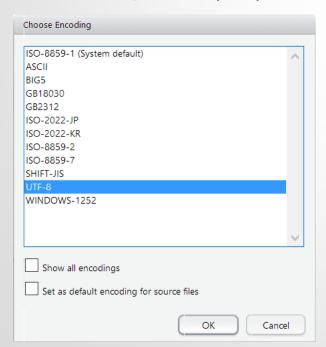
R 3.3.0 x64 (OS Windows 10)

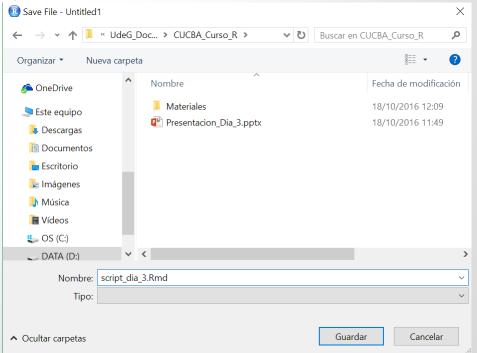
```
RStudio
File Edit Code View Plots Session Build Debug Tools Help
• Go to file/function
  Untitled1* ×
                                                                                                                 _0
  🗇 🖒 🔎 🔝 🔒 🏕 Knit HTML 🕶 🚳 🕶
                                                                                          🖎 | ☆ 🕹 | 📑 Run 🕶 多
    2 title: "Taller de R básico. Dia 3."
    3 author: "Viacheslav Shalisko"
    4 date: "19 de octubre de 2016"
    5 output: html_document
    6 - ---
    8, ```{r setup, include=FALSE}
   11
   12 - ## Prueba 1
   13
   14
   15 + ```{r}
                                                                                                           16
   17 -
   18
   19
   20
   21
   22
   23
   24
   25
   26
   27
   22:1
       Prueba 1 🛊
                                                                                                            R Markdown $
```

#### **Entorno**

#### Notas:

- Para poder representar de forma correcta los símbolos especiales (letras con acento, letras del alfabeto griego, etc.) se requiere especificar la codificación UTF-8.
- Guardar el script como el archivo en el formato R Markdown con la extensión .Rmd
- Knit as HTML
- Primera vez que se ejecuta Knit puede ser necesario instalar las bibliotecas adicionales (knitr y dependencias)





#### Entorno

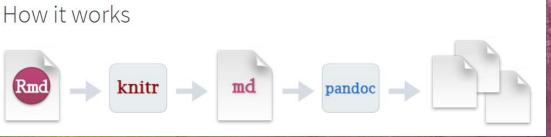
#### Resultado



El formato *R Markdown* permite elaborar los documentos que contienen el código fuente en R, los resultados de su ejecución y el texto de comentarios.

Inclusión del código junto con los resultados en el mismo documento es parte de la estrategia para realizar la investigación reproducible. La entrega del código fuente de análisis junto con los resultados permite a otros científicos comprender la estructura del procedimiento y repetirlo.







Get Started

Gallery

Formats

Articles





Analyze. Share. Reproduce.

Your data tells a story. Tell it with R Markdown. Turn your analyses into high quality documents, reports, presentations and dashboards.

Consulta la pagina web <a href="http://rmarkdown.rstudio.com">http://rmarkdown.rstudio.com</a> para conocer ideología R Markdown

#### **Datos fuente**

La tabla de datos Datos\_del\_censo.csv – contiene fragmento de estudio del arbolado con DAP ≥ 5 cm en los Centros Universitarios de la UdeG (datos del 2016)

Así se ve el código en el editor de RStudio

El resultado de ejecución con el compilador Knit

```
12 - ### A. Cargar la tabla de datos
13 - #### Estructura de datos (tabla `Datos_del_censo.csv`):
   1. *Centro* - código del CU
  2. *Especie* - nombre científico
  3. *Codigo* - identificador único del arbol
  4. *AB* - área basal del árbol (dm^2^)
18 5. *DTr* - diametro del tronco equivalente (cm)
19 6. *Alt* - estatura del árbol (m)
20 7. *DCop* - diametro promedio de la copa (m)
   8. *ExcCop* - excentricidad de la copa
22
23 + ```{r}
   arbolado <- read.csv("Materiales/Datos_del_censo.csv")</pre>
    dim(arbolado)
26 -
28
29
       fragmento del código R ("chunk")
30
31
32
33
```

#### A. Cargar la tabla de datos

Estructura de datos (tabla Datos del censo.csv):

- 1. Centro código del CU
- 2. Especie nombre científico
- 3. Codigo identificador único del arbol
- 4. AB área basal del árbol (dm2)
- 5. *DTr* diametro del tronco equivalente (cm)
- 6. Alt estatura del árbol (m)
- 7. DCop diametro promedio de la copa (m)
- 8. ExcCop excentricidad de la copa

```
arbolado <- read.csv("Materiales/Datos_del_censo.csv")
dim(arbolado)</pre>
```

## [1] 4785

8

### **Datos fuente**

```
head(arbolado) 
Verificación de calidad de lectura de tabla
```

```
Especie Codigo AB DTr Alt DCop ExcCop
     Centro
##
## 1 CUCOSTA Pithecellobium dulce C10-3-1 13.21 41.0 9.8 15.4
                                                                0.30
                  Acacia macracantha C10-3-10 1.91 15.6 4.4 4.7
## 2 CUCOSTA
                                                                0.63
## 3 CUCOSTA Pithecellobium lanceolatum C10-3-100 0.95 11.0 6.4 9.5
                                                                0.91
## 4 CUCOSTA
                  Salix bonplandiana C10-3-1000 0.83 10.3 7.7 4.9 0.20
                      Tabebuia rosea C10-3-1001 0.28 6.0 2.4 2.0 0.63
## 5 CUCOSTA
## 6 CUCOSTA Pithecellobium lanceolatum C10-3-1002 0.51 8.1 4.1 4.3
                                                                0.71
```

#### tail(arbolado)

```
## Centro Especie Codigo AB DTr Alt DCop ExcCop ## 4780 CUCSUR Araucaria heterophylla C9-3-94 6.97 29.8 16.2 5.5 0.50 ## 4781 CUCSUR Ficus benjamina C9-3-95 17.60 47.3 11.5 10.2 0.38 ## 4782 CUCSUR Simarouba glauca C9-3-96 2.63 18.3 11.5 9.4 0.58 ## 4783 CUCSUR Jacaranda mimosifolia C9-3-97 76.95 99.0 20.6 13.0 0.57 ## 4784 CUCSUR Jatropha cordata C9-3-98 2.11 16.4 2.7 3.6 0.23 ## 4785 CUCSUR Jacaranda mimosifolia C9-3-99 7.55 31.0 18.2 5.2 0.77
```

### **Datos fuente**

#### Estructura del objeto arbolado

```
str(arbolado)
```

#### levels(arbolado\$Centro)

```
## [1] "CUALTOS" "CUCIENEGA" "CUCOSTA" "CUCSUR"
```

#### summary

```
summary(arbolado[,c(1,2,4:8)]) 			 Seleccionamos solo columnas de interés
```

```
Especie
##
        Centro
                                                 AB
                                            Min. : 0.200
## CUALTOS :1828 Quercus resinosa : 530
## CUCIENEGA: 445 Pithecellobium lanceolatum: 501 1st Qu.: 0.950
## CUCOSTA :2143 Guazuma ulmifolia : 329 Median : 2.780
## CUCSUR : 369 Fraxinus uhdei : 278 Mean : 5.817
##
                 Eysenhardtia polystachya : 245
                                            3rd Qu.: 6.610
                 Acacia macracantha : 176
##
                                            Max. :456.340
##
                 (Other)
                                 :2726
##
       DTr
                   Alt
                                  DCop ExcCop
   Min. : 5.00 Min. : 1.500 Min. : 0.200 Min. : 0.0000
   1st Qu.: 11.00    1st Qu.: 4.200    1st Qu.: 3.800    1st Qu.:0.3700
   Median: 18.80 Median: 6.200 Median: 5.500 Median: 0.5100
##
   Mean : 22.22 Mean : 7.121 Mean : 6.165
                                            Mean :0.5026
##
## 3rd Qu.: 29.00 3rd Qu.: 9.100 3rd Qu.: 7.900 3rd Qu.:0.6500
   Max. :241.00 Max. :26.600
                              Max. :64.500 Max. :0.9900
##
                NA's :46
##
                                Variable sin datos
```

### mean, median, sd, var, quantile

Las funciones básicas de la estadistica descriptiva incluyen:

- Promedio y mediana mean(), median()
- 2. Mínimo, máximo y rango min(), max(), range()
- 3. Desviación estandar y varianza sd(), var()
- 4. Quantiles y rango intercuartilico quantile(), IQR()

```
summary(arbolado$AB)
```

```
## Min. 1st Qu. Median Mean 3rd Qu. Max.
## 0.200 0.950 2.780 5.817 6.610 456.300
```

range(arbolado\$AB)

```
## [1] 0.20 456.34
```

quantile(arbolado\$AB)

```
## 0% 25% 50% 75% 100%
## 0.20 0.95 2.78 6.61 456.34
```

```
IQR(arbolado$AB)
```

```
## [1] 5.66
```

```
var(arbolado$AB)
```

```
## [1] 173.8403
```

```
sqrt(var(arbolado$AB))
```

```
## [1] 13.18485
```

sd(arbolado\$AB)

```
## [1] 13.18485
```

### quantile, boxplot.stats

Función *quantile* se puede emplear para subdividir la distribución de valores bajo reglas arbitrarias, determinar cuartiles, percentiles o cualquier otra secuencia de probabilidades.

```
probabilidades <- c(0.01,0.05,0.1,0.5,0.9,0.95,0.99)
quantile(arbolado$AB, probs = probabilidades)

## 1% 5% 10% 50% 90% 95% 99%
## 0.200 0.270 0.410 2.780 12.956 19.630 44.436</pre>
```

Función *boxplot.stats* puede ser útil para discriminar los valores atípicos. Este procedimiento depende del umbral *coef* definido en los parámetros, valor por defecto coef=1.5

```
boxplot.stats(arbolado$AB)$stats b
## [1] 0.20 0.95 2.78 6.61 15.00 #
```

```
boxplot.stats(arbolado$AB, coef = 3)$stats
## [1] 0.20 0.95 2.78 6.61 23.52
```

### aggregate

Estadísticas por grupos se puede calcular empleando función aggregate.

Nota que los grupos deben estar definidos como variable de tipo factor.

```
aggregate(arbolado$AB ~ arbolado$Centro, FUN = sum)
```

```
## 1 CUALTOS 8521.96
## 2 CUCIENEGA 3478.53
## 3 CUCOSTA 12647.99
## 4 CUCSUR 3184.82
```

```
aggregate(arbolado$AB ~ arbolado$Centro, FUN = length)
```

### aggregate

```
aggregate(arbolado$AB ~ arbolado$Centro, FUN = mean)
```

```
aggregate(arbolado$AB ~ arbolado$Centro, FUN = range)
```

```
## 1 CUALTOS 0.20 114.36
## 2 CUCIENEGA 0.23 77.44
## 3 CUCOSTA 0.20 456.34
## 4 CUCSUR 0.21 419.84
```

### apply, lapply, sapply, tapply, mapply

#### Estadistica por columnas y/o grupos

El grupo de funciones apply permite realizar operaciones de forma cíclica sin necesidad de definir un ciclo de manera formal:

- 1. lapply() aplicar una función a cada elemento de una lista, resultado es una lista de mismo largo que lista de entrada
- 2. sapply() lo mismo que lapply(), pero con resultado simplificado (vector, matriz o array)
- 3. apply() aplicar una función sobre dimensiones de un matriz de datos

aggregate(arbolado\$AB ~ arbolado\$Centro, FUN = mean)

- 4. tapply() aplicar una función sobre grupos definidos en un vector, similar a aggregate()
- 5. mapply() versión multivariante de tapply()

#### Compara

```
tapply(arbolado$AB, arbolado$Centro, FUN = mean)

## CUALTOS CUCIENEGA CUCOSTA CUCSUR
## 4.661904 7.816921 5.902002 8.630949
```

```
## arbolado$Centro arbolado$AB
## 1 CUALTOS 4.661904
## 2 CUCIENEGA 7.816921
## 3 CUCOSTA 5.902002
## 4 CUCSUR 8.630949
```

### lapply, sapply

```
Compara lapply() y sapply()
 lapply(arbolado[,4:8],sd,na.rm = TRUE)____
 ## $AB
 ## [1] 13.18485
 ##
 ## $DTr
 ## [1] 15.71243
 ##
 ## $Alt
 ## [1] 3.847538
 ##
 ## $DCop
 ## [1] 3.352365
 ## $ExcCop
 ## [1] 0.2009095
 sapply(arbolado[,4:8],sd,na.rm = TRUE)
```

Nota que se agrega el parámetro para omitir valores sin datos, el mismo parámetro se puede aplicar a funciones individuales.

```
sd(arbolado$Alt, na.rm = TRUE)
```

```
## [1] 3.847538
```

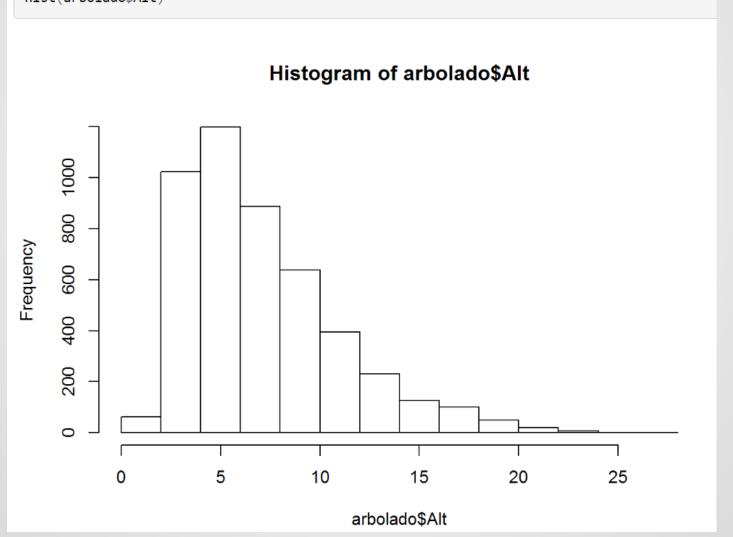
```
## AB DTr Alt DCop ExcCop
## 13.1848514 15.7124261 3.8475377 3.3523652 0.2009095
```

### sapply

```
sapply(arbolado[,4:8],range,na.rm = TRUE)
## AB DTr Alt DCop ExcCop
## [1,] 0.20 5 1.5 0.2 0.00
## [2,] 456.34 241 26.6 64.5 0.99
sapply(arbolado[,4:8],function(x) length(x[!is.na(x)]))
                                            función anónima
## AB DTr Alt DCop ExcCop
## 4785 4785 4739 4785 4785
```

A veces se puede definir una *función anónima* en la misma estructura de *apply*. Es el método muy común de uso de las estructuras apply.

hist(arbolado\$Alt)



```
hist(arbolado$Alt,

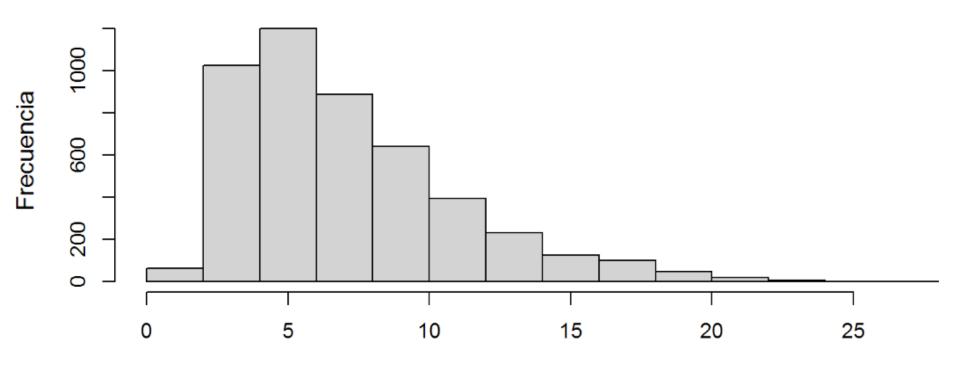
col = "lightgray",

xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",

main = "Histográma de estaturas")
```

Parámetros del "chunk".

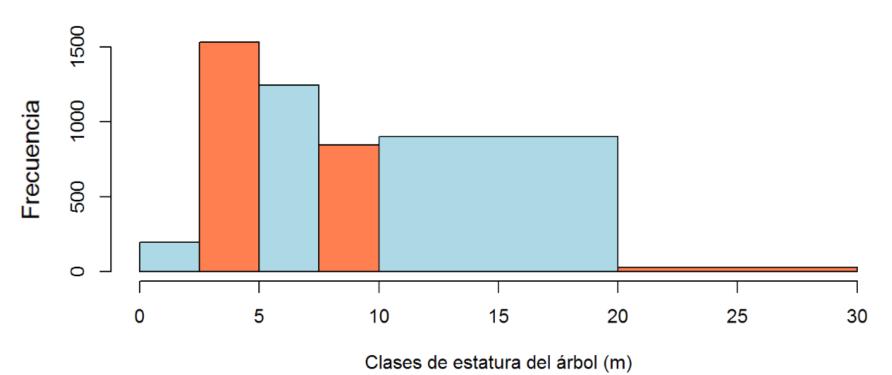
#### Histográma de estaturas



Clases de estatura del árbol (m)

```
hist(arbolado$Alt,
    col = c("lightblue","coral"),
    xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
    main = "Histográma de estaturas",
    breaks = c(0,2.5,5,7.5,10,20,30), prob = FALSE)
```

#### Histográma de estaturas



```
H0 <- hist(arbolado$Alt,
    col = c("lightblue","coral"),
    xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
    main = "Histográma de estaturas",
    breaks = c(0,2.5,5,7.5,10,20,30), prob = FALSE)</pre>
```

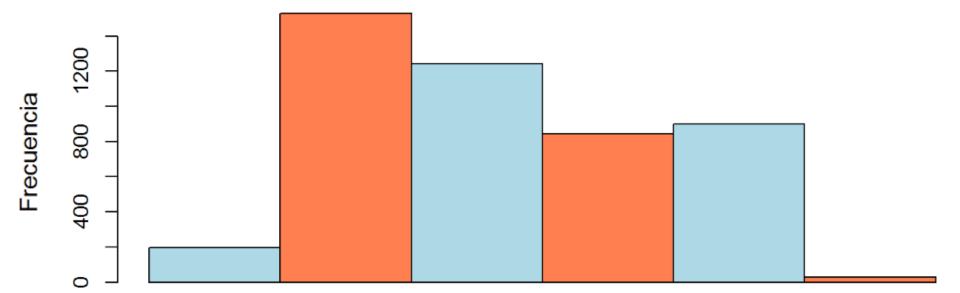
#### str(H0)

```
## List of 6
## $ breaks : num [1:7] 0 2.5 5 7.5 10 20 30
## $ counts : int [1:6] 196 1529 1242 844 900 28
## $ density : num [1:6] 0.0165 0.1291 0.1048 0.0712 0.019 ...
## $ mids : num [1:6] 1.25 3.75 6.25 8.75 15 25
## $ xname : chr "arbolado$Alt"
## $ equidist: logi FALSE
## - attr(*, "class")= chr "histogram"
```

### barplot

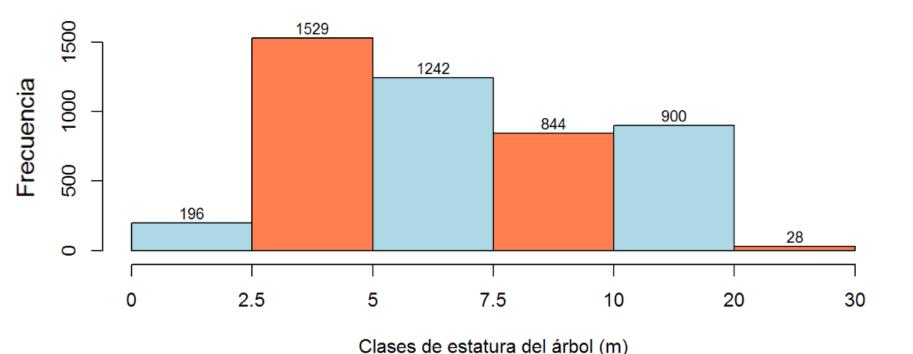
```
barplot(H0$counts, space = 0,
    col = c("lightblue","coral"),
    xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
    main = "Histográma de estaturas")
```

#### Histográma de estaturas



### barplot

#### Histográma de estaturas

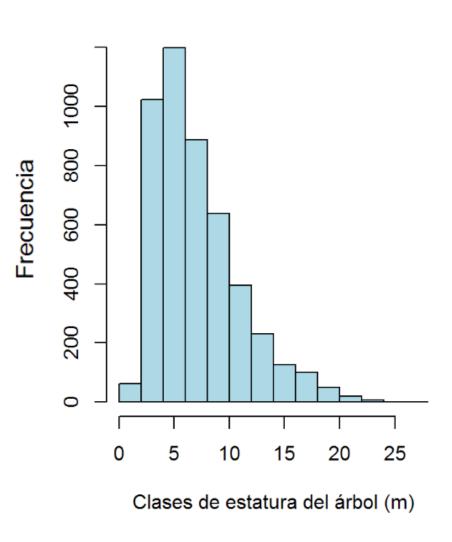


La función *plot* ofrece gran flexibilidad en elaboración de las graficas bidimensionales.

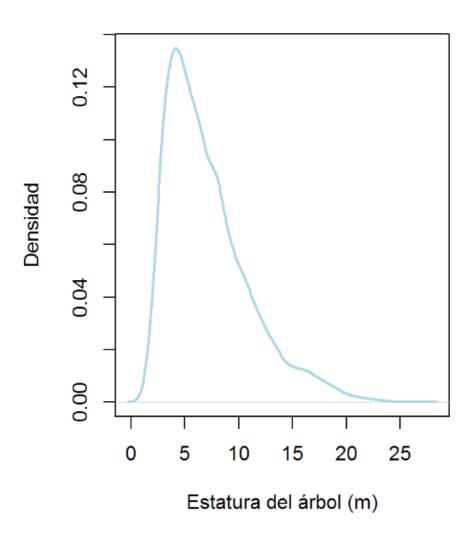
Parámetros para colocar 2 gráficas en un cuadro

### plot vs. hist

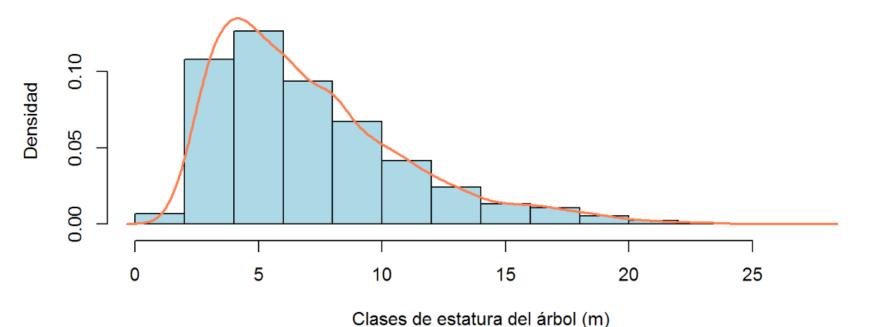
#### Histográma de estaturas



#### Distribución de estaturas



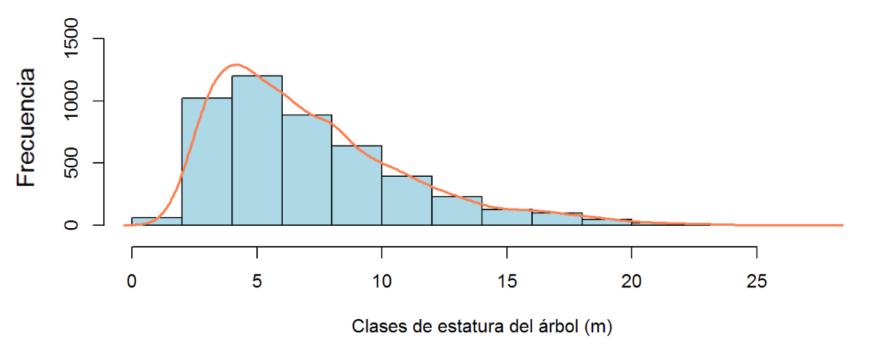
#### Histográma de estaturas con gráfica de densidad de distribución



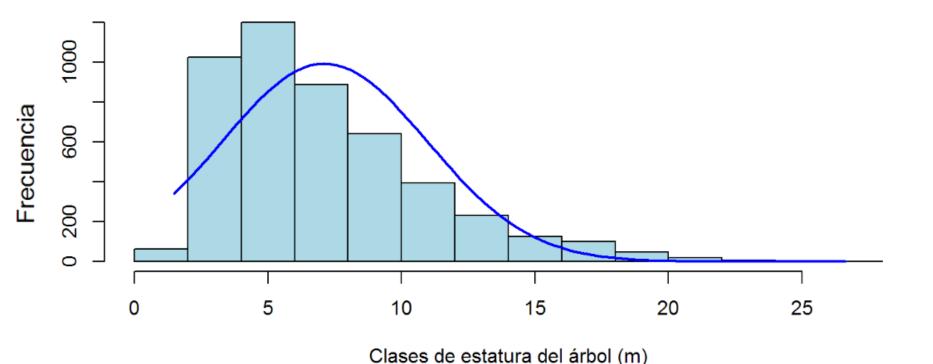
```
H2 <- hist(arbolado$Alt, ylim = c(-100,1700),
        col = c("lightblue"),
        xlab = "Clases de estatura del árbol (m)", ylab = "Frequencia",
        main = "Histográma de estaturas con gráfica de densidad de distribución", prob = FALSE)

densidad <- density(arbolado$Alt, na.rm = TRUE)
densidad$y <- densidad$y*diff(H2$mids[1:2])*length(arbolado$Alt)
lines(densidad, col = c("coral"), lty=1, lwd=2)</pre>
```

#### Histográma de estaturas con gráfica de densidad de distribución

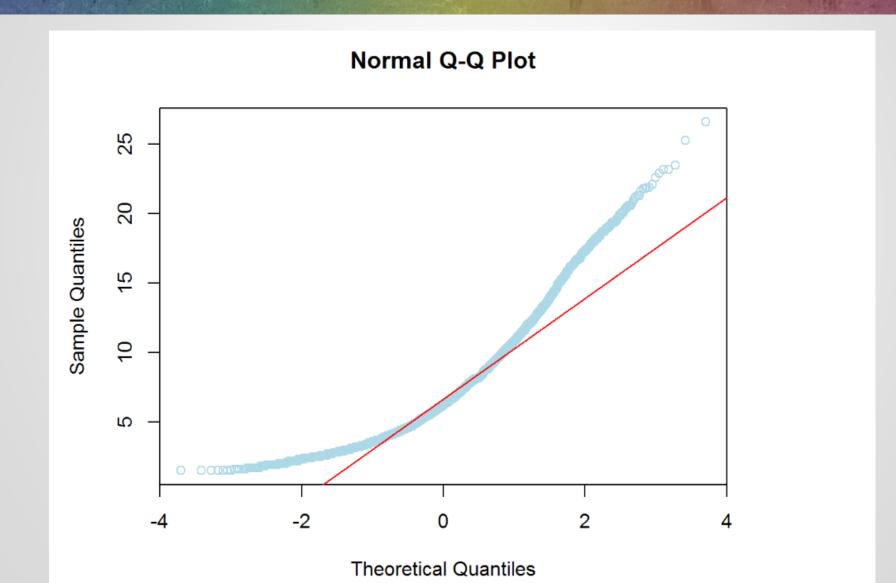


#### Histográma de estaturas con grafica de distribución normal

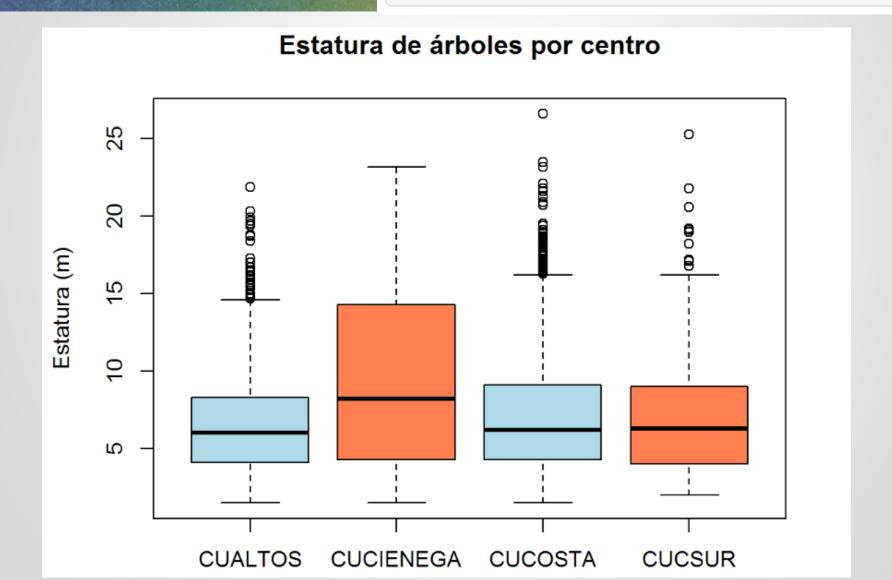


### qqnorm

```
qqnorm(arbolado$Alt, col = "lightblue")
qqline(arbolado$Alt, col = "red")
```

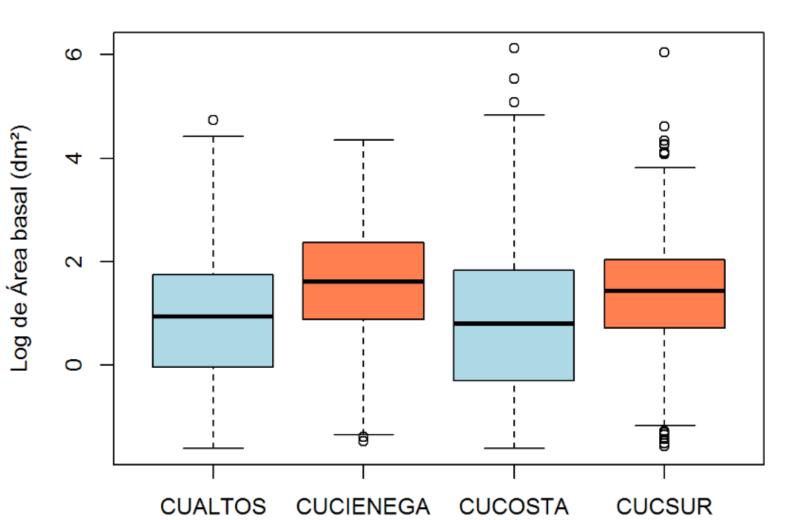


# boxplot

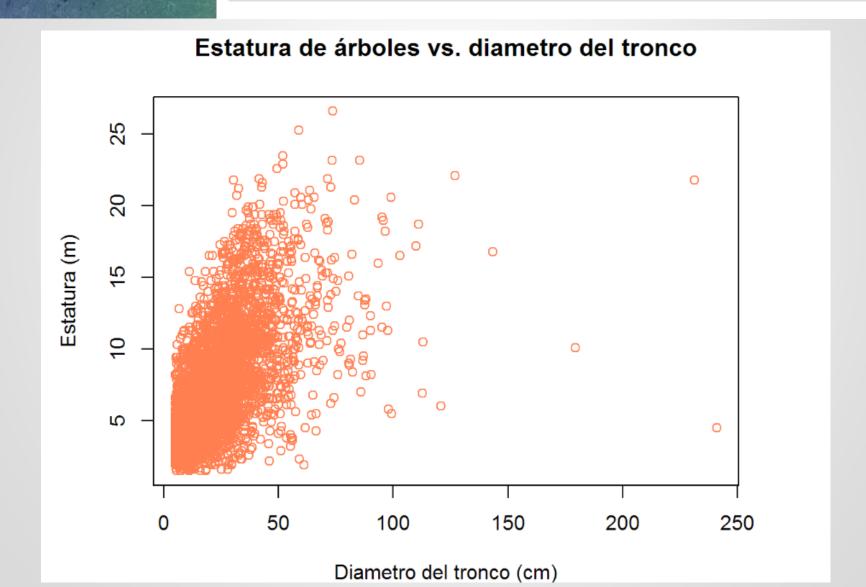


## boxplot

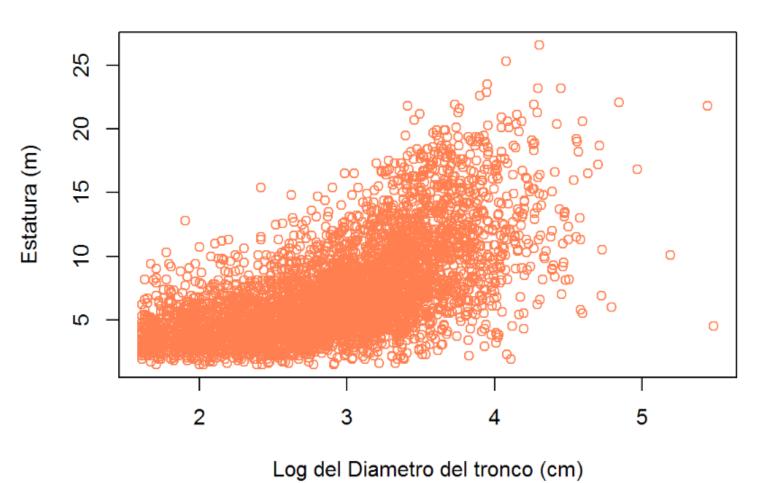
#### Área basal de árboles por centro







#### Estatura de árboles vs. diametro del tronco

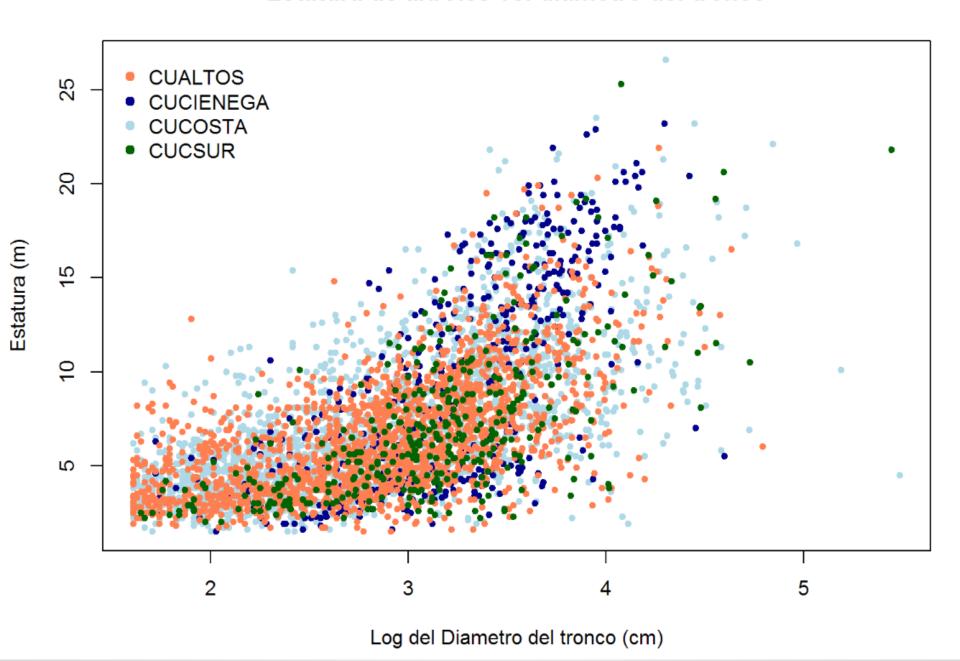


plot

Vector de cuatro colores se asocia con los cuatro niveles del factor presentes en la variable categórica

Nombres de niveles de variable categórica se usan como parámetros de leyenda, y la secuencia de cuatro colores como parámetro col

#### Estatura de árboles vs. diametro del tronco



### funciones

Sintáxis general de definición de las funciones

```
nombre_de_función <- function(variables_de_entrada) {
cuerpo de función donde se usan las variables de entrada y se genera valor de salida
}
```

Existen la dos formas de definición de las funciones:

- a) en una sola linea
- b) con el bloque encerrado en los símbolos {}

Las funciones pueden ser anónimas o tener el nombre

```
trim <- function(x) gsub("^\\s+|\\s+$", "", x)
simpleCap <- function(x) {
   paste(toupper(substr(x, 1, 1)), substr(x, 2, nchar(x)), sep="")
}</pre>
```

#### funciones

Aplicacion de las funciones para depurar nombres de las especies

```
lista_especies <- unique(as.character(arbolado$Especie))
length(lista_especies)</pre>
```

```
## [1] 150
```

```
arbolado$Especie <- sapply(as.character(arbolado$Especie), simpleCap)
arbolado$Especie <- sapply(arbolado$Especie, trim)
lista_depurada_especies <- unique(arbolado$Especie)
arbolado$Especie <- as.factor(arbolado$Especie)

length(lista_depurada_especies)</pre>
```

```
## [1] 144
```

### elementos de control

#### Elementos de control de flujo de ejecución

- 1. if, else, else if estructuras condicionales
- 2. for ciclos (loops, bucles) con un número predeterminado de iteraciones
- 3. while ciclos con un número indefinido de iteraciones
- 4. repeat ciclos con un número infinito de iteraciones (se usan rara vez, principalmente en elementos de interface de usuario)
- 5. next, return elementos que permiten interrimpir o saltar iteraciones en los ciclos

Sintáxis general de las estructuras condicionales

```
if(condición lógica) {
  código para caso que la condición se cumple
} else {
  código para caso que la condición no se cumple
}
```

Sintáxis general de los ciclos con numero predeterminado de elementos

```
for(iterador in rango_de_posibles_valores_del_iterador) {
  código del cuerpo de ciclo, donde se puede utilizar iterador como una variable
}
```

### elementos de control

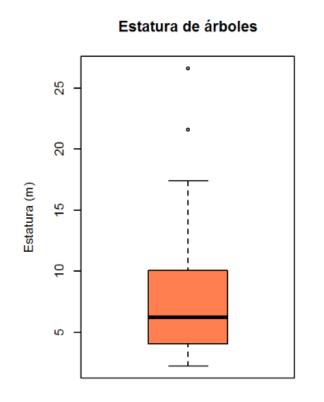
Ejemplo:

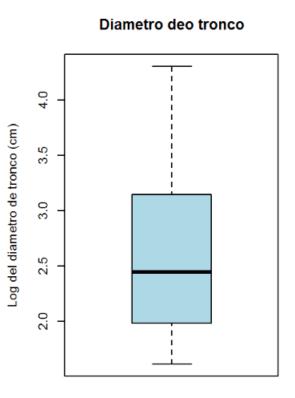
```
for(i in 1:length(lista depurada especies)){
  # seleccionar registros que corresponden a una especie determinada
  tabla_especie <- arbolado[arbolado$Especie == lista_depurada especies[i],]
  # verificar que número de árboles de la especie es mayór que 50
  if(dim(tabla especie)[1] > 50) {
    # imprimir nombre de especie y número de árboles
    cat(paste("<h4><i>",lista depurada especies[i],"</i></h4>"))
    cat(paste('<code>',"n =",dim(tabla especie)[1],"</code>"))
    # especificar lienzo para tres graficas
    par(mfcol = c(1, 3))
    # dobujar tres graficas
    boxplot(tabla especie$Alt,
        col = "coral", main = "Estatura de árboles", ylab = "Estatura (m)")
    boxplot(log(tabla_especie$DTr),
        col = "lightblue", main = "Diametro deo tronco", ylab = "Log del diametro de tronco (cm)")
    plot(tabla_especie$Alt ~ log(tabla_especie$DTr),
        col = "coral", main = "Estatura vs. diametro del tronco",
       vlab = "Estatura (m)", xlab = "Log del diametro del tronco (cm)")
```

### elementos de control

#### Tabebuia rosea

n = 159





# Estatura vs. diametro del tronco 20 Estatura (m) 10 3.5

Log del diametro del tronco (cm)

### estructuras de control

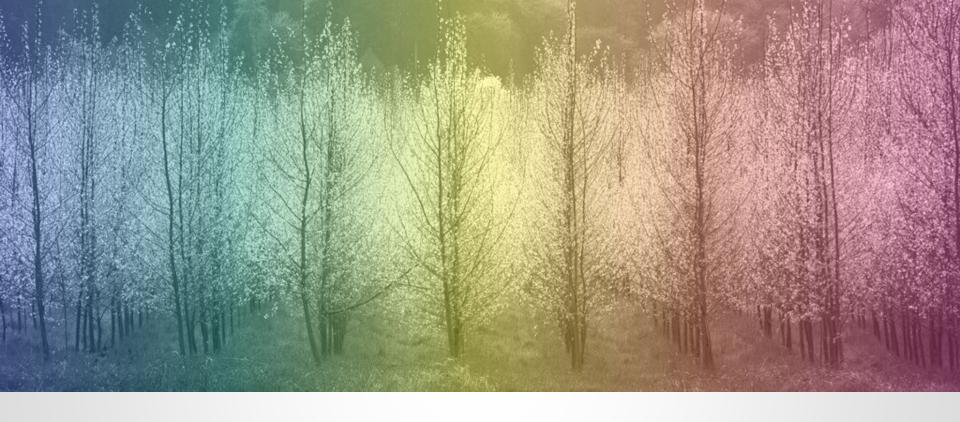
Seguir con ponencia de R. Peng de John Hopkins University (disponible en Coursera, parte del curso "R programming")



## Introduction to the R Language

**Control Structures** 

Roger Peng, Associate Professor Johns Hopkins Bloomberg School of Public Health



### **Gracias**